


Rezumat

Cercetarea și diagnosticarea afecțiunilor neurologice reprezintă domenii fundamentale în medicina modernă, având un impact semnificativ asupra sănătății publice.

S-a constatat că **vârsta creierului** este legată de îmbătrânirea cognitivă și de mai multe aspecte ale îmbătrânirii fiziologice, având și capacitatea de a prezice riscul de **boli neurodegenerative** [1].



Keywords: age prediction, regression models, data manipulation

Setul de date

Setul de date furnizat de WiDS [2] conține **1104 date de antrenament** și **474 de test**, reprezentând informații despre pacienți. Datele sunt furnizate sub formă de fișiere CSV, fiecare având o matrice de coeficienți de corelație între regiunile creierului de dimensiune 200x200 [3]. În plus, este inclus și un set de metadate asociate, care furnizează informații suplimentare relevante pentru analiză (sex, bmi, rasă, etnie, etc.).

Asupra setului de date s-au efectuat **prelucrări** precum:

- extragerea matricei superior triunghiulare
- gestionarea valorilor lipsă (înlocuirea acestora cu 'unknown' sau cu o valoare medie)
- asocierea de coduri one-hot șirurilor de caractere pentru utilizarea lor în algoritmi de predicție
- normalizarea valorilor numerice pentru a aparține intervalului [-1, 1]




Fig 1. Datele matricei extrase din fMRI [4]

Algoritmi de predicție

Utilizarea algoritmilor de predicție a vârstei este susținută de abilitatea lor de a identifica diferențele subtile în structura și funcționarea creierului [5].

Odată cu integrarea metadatelor setul de date cu ajutorul căruia se realizează predicția, s-a observat că un algoritm a demonstrat performanțe superioare față de cei care în fază primară ofereau rezultate satisfăcătoare (cei de tip liniar).

Dezvoltarea s-a realizat ulterior pe **Support Vector Regression** cu kernel **Gaussian**, cu un set de parametri testați ce au îmbunătățit eroarea pătratică medie.

Printre optimizări se numără aplicarea algoritmului **K-Means** asupra datelor din matricele fMRI, utilizând două cluster.

Rezultate

Tabel 1. Evoluția rezultatelor

Algoritm	RMSE	Detalii
Ridge	1.90871	fMRI
SVR liniar	1.89681	fMRI
SVR liniar	1.87253	fMRI + metadata
SVR rbf	1.82258	fMRI + metadata + parametri optimi
SVR rbf	1.82248	fMRI + metadata + parametri optimi + clusterizare

Prin simpla adăugare la setul datelor de antrenare a metadatelor prelucrate s-a obținut o creștere a performanței.

Impactul cel mai semnificativ l-a avut testarea parametrilor optimi pentru SVR, ceea ce a dus la modificarea kernelului din liniar în Gaussian.

Adăugarea **clusterelor** pentru datele fMRI reprezintă algoritmul cel mai performant. Acesta aduce o reducere ușoară a RMSE-ului, însă indică faptul că gruparea datelor în subseturi relevante poate îmbunătăți predicțiile.

În Fig. 2, pentru o mai bună vizualizare a erorii pe setul de date de antrenament și reducerea variației acestora s-a aplicat **K-Fold** cu $k = 5$. Performanțele diferite între fold-uri indică faptul că algoritmul are o performanță mai bună pe anumite seturi de date, deoarece distribuția pacienților nu este uniformă.




Fig 2. Valoarea erorii pătratică pe 20% din setul de antrenare

Tehnologii utilizate

Biblioteci Python:

- Pandas
- Scikit-Learn (preprocessing, models, metrics, feature selection, cluster)
- Numpy

Computing Services:

- Google Colab
- Kaggle notebook

Discuții

Pe tot procesul de dezvoltare s-au testat diferite metode de optimizare a setului de date pentru a spori predicția modelului, dar fără succes. Din acestea amintim:

- **Scorul Silhouette** pentru a stabili numărul de cluster: valoarea maximă foarte apropiată de 0 sugerează că datele au caracteristici care îngreunează identificarea structurilor.
- **Select K Best** pentru selecția caracteristicilor: s-a calculat scorul fiecărui element din matricea fMRI pentru a afla relevanța sa în raport cu variabila țintă. Testarea modelului fără elementele cu scoruri mici însă nu a adus îmbunătățiri, indicând faptul că este posibil ca dimensionalitatea datelor să nu reprezinte o problemă.

Totuși, concluziile acestor teste nu sunt definitive, există și alți algoritmi și metode de optimizare care ar putea contribui la îmbunătățirea performanței predicției.

Concluzii

- S-a obținut cel mai bun rezultat cu **RMSE de 1.82248**.
- S-a efectuat o mai bună prelucrare a setului de date.
- S-a obținut o determinare mai bună a erorii pe datele de antrenare.

Contact

Antal Simona
Samachiș Eduard-Iulian

simona.antal@student.tuiasi.ro
eduard-iulian.samachis@student.tuiasi.ro

Facultatea de Automatică și Calculatoare
Specializarea: Calculatoare și Tehnologia Informației
Anul de studiu: III
Grupa: 1308A

Referințe

- [1] Hedieh Sajedi, Nastaran Pardakhti, "Age Prediction Based on Brain MRI Image: A Survey", 2019
- [2] WiDS Datathon++ University Challenge 2025 dataset, <https://www.kaggle.com/competitions/widsdatathon2025-university/data>
- [3] WiDS 2025 University Workshop, "Data Dictionary for specific regions of the brain", <https://docs.google.com/spreadsheets/d/10cFuj8whV87ATjz1luqTHxiZq-m7zQ47bKq0NtB3aw/edit?gid=0#gid=0>
- [4] Young-Beom Lee et al., "Brain-State Extraction Algorithm Based on the State Transition (BEST): A Dynamic Functional Brain Network Analysis in fMRI Study", 2019
- [5] L.K. Soumya Kumari, R. Sundararajan, "A review on brain age prediction models", 2024, Brain Research 148668